

[PCA] 차원 축소 정리]

(중요한 점을...)

PCA로 선형독립인 점을 놓기는
축소, 양축 작업!

DS에서, 열(벡터) 간 선형 종속이 있어, 그대로 쓸 수 없고, 어려워지기 때문에

• PCA : 차원 축소 의미 (노이즈 제거, 데이터, 연산량 ↓)

• Latent variable로 데이터를 양축 해준다.
(차원축소)

ex) '꽃의 크기'라는 잠재적 변수가 '꽃의 폭', '꽃의 높이'라는
데이터로 세분화되어 표현된 것일 뿐.

* Latent variable : 바로 측정되지는 않지만, 특정된 데이터들의
기준에 따라서 측정 데이터를 결정짓는 것
PCA는 이 잠재변수들을 활용
공간을 구성한다.
(더 낮은 차원으로)

* PCA의 가정 : $u_i = w^T \underline{x}_i$

(u_i = 잠재변수 = 측정데이터 벡터 (\underline{x}_i)의
각 원소를 포함해 만든 것)
가중치 벡터 = w

측정데이터 잠재변수가

선형관계에 있다는 가정.

ex) $u_i = w_1 \underline{x}_{i1} + w_2 \underline{x}_{i2}$

; 잔차 꽃크기 꽃길이 관측data 꽃폭 관측data

• Latent variable (z) \Leftrightarrow 이를 구성하는 가중치 벡터 (w),
(w_1, w_2)

어떻게? 예시나 선형逼近에 드시!

= 차원근사 (로우랭크 근사 문제)

= 투영 문제 \Leftrightarrow 차원축소 문제

+
"근사성능 높이기 위해 직선이 원점을
지나야 한다는 제한 조건 없음"

PCA : N 개의 차원 베ktor x_1, \dots, x_n 에서 특정 베ktor x_0 를 뺀 $x_1 - x_0, \dots, x_n - x_0$ 를 정규직교 ~~기저~~ 베ktor w_1, \dots, w_K 로 이루어진 차원 공간에 특별히

x_1, \dots, x_n 대비하여 가장 많은 $x_1^T w, \dots, x_n^T w$ 을 만들기 위한

정규직교 ~~기저~~ 베ktor w_1, \dots, w_K 와 상수 베ktor c_0 을 찾는다.

($\circ n$) $\cdot \vec{x}_0$ 는 $\frac{1}{N} (\vec{x}_1 + \dots + \vec{x}_n)$ 평균 베ktor

w_1, \dots, w_K 는 내림차순 N 개 특이값에 대응하는 우특이 베ktor v_1, \dots, v_K 이다.

$$x^T w = c \quad ; \quad \text{부여되는 } c$$

$$x^T v = 0 \quad ; \quad \text{부여되는 } 0$$

$$(x^T w)^2 + (x^T v)^2 = c^2 \quad (1)$$

$$\text{도입하는 } v$$

$$x^T w + x^T v = c \quad (2)$$

$$\text{도입하는 } v$$

$$c^2$$

$$(x^T w)^2 + (x^T v)^2 = c^2 \Leftrightarrow |x^T w| = c \quad (3)$$

$$(x^T w)^2$$

$$|x^T w| = c$$

$$|x^T w|^2 = c^2$$

$$x^T w = c$$

[PCA 수학적 정리]

$$1) \hat{x}_i = w \bar{x}_i \quad \Leftrightarrow \quad \begin{matrix} k \times 1 \\ k \times m \\ k \times m \end{matrix}$$

$$\begin{bmatrix} \hat{x}_{i1} \\ \vdots \\ \hat{x}_{ik} \end{bmatrix} = \begin{pmatrix} w_{11} & w_{1m} \\ \vdots & \vdots \\ w_{k1} & w_{km} \end{pmatrix} \begin{bmatrix} x_{i1} \\ \vdots \\ x_{im} \end{bmatrix}$$

$$\hat{X} = X W^T$$

$$\begin{bmatrix} \hat{x}_1 \\ \vdots \\ \hat{x}_n \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} W^T$$

$$n \times k \quad n \times m \quad m \times k = (k \times m)^T$$

2) So, \hat{x}_i 와 x_i

\hat{x}_i 와 X 를 가장 유사하게 해주는

W (변환행렬) 을 찾는다.

3) 비교는 $\|x_i - \hat{x}_i\|$ 로

그 전에! W 의 역기능하는 U 도 찾아야 함.

($M \rightarrow K$ 차원)

($K \rightarrow M$ 차원)

원상복구, 차원회복

* x_i 와 \hat{x}_i 는 서로 차원이 달라 직접 비교 불가.

ex) (3, 2, 1, 4) (2, 1)

$\therefore \hat{x}_i$ 를 다시 원래 차원으로 돌려서 비교해준다!

$$\hat{x}_i = U \hat{x}_i \quad \longleftrightarrow \quad x_i$$

M 차원

* $WU = I$,

$$\hat{x} = U \hat{x}, \quad W \hat{x} = \hat{x} = WU \hat{x}$$

$\therefore WU = I$

$$4) \text{So, } \arg \min_{\hat{x}} \|x - U \hat{x}\|^2$$

$$\|x - U \hat{x}\|^2 = (x - U \hat{x})^T (x - U \hat{x}) = (x^T - \hat{x}^T U^T)(x - U \hat{x})$$

$$= x^T x - 2x^T U \hat{x} + \hat{x}^T U^T x$$

) x 로 미분,

$$-2 U^T x + 2 \hat{x} = 0$$

$$\Leftrightarrow \hat{x} = U^T x, \quad \hat{x} = Wx$$

$$\Leftrightarrow U^T = W, \quad U = W^T, \quad W^T W = I$$

$$5) W \text{ 찾기는 Rank } - k \text{ 을 사용! } \arg \min_{W} \|x - x W^T W\|^2$$

3