

3.0 고급 선형대수

1) 벡터의 길이

- $\|a\| = \sqrt{\vec{a}^T \vec{a}} = \sqrt{a_1^2 + \dots + a_n^2}$

- 단위벡터

3.1 선형대수와

해석기하의 기초

2) 유클리드 거리

- 정의

3) 벡터의 내적과 삼각함수

- 내적 = $\vec{a} \cdot \vec{b} = \vec{a}^T \vec{b} = \|\vec{a}\| \|\vec{b}\| \cos \theta$

- $\sin, \cos = \frac{\text{opposite}}{\text{hypotenuse}}, \frac{\text{adjacent}}{\text{hypotenuse}}$

4) 직교

- 정의

5) 정규직교

- 정의



$\|v_i\| = 1, v_i^T v_i = 1, v_i^T v_j = 0 (i \neq j)$

- 정규직교 벡터의 역행렬 = 전치행렬

6) 코사인 유사도

- 정의

- 벡터 간 거리 : 코사인 거리 / 유클리드 거리

$= \frac{\cos \theta}{\|\vec{a} - \vec{b}\|}$

3.0 고급 선형대수 03.01 선형대수와 해석기하의 기초

3.1 선형대수와 해석기하의 기초 7) 벡터의 분해와 성분

- $a + b = c$, $c = a$ 와 b 로 분해될 수 있음. c 라는 벡터의 분해는 (a,b) 외에도 수 많은 조합으로 가능

8) 정사영

- 정사영은 벡터와 직선(or 벡터) 간 수직거리 이해에 필요

- 벡터 a 를 정사영과 직교성분으로 분해

- 정사영 길이 = $\|a\| \cos$


- 정사영 길이 = 내적값 / $\|b\|$

- 정사영 길이 = 벡터 a 와 단위벡터(b 의) 내적

- 정사영 벡터 = 정사영 길이 * 단위벡터

- 벡터 $a = a$ 의 정사영 벡터 + a 의 직교벡터


[정사영의 길이]



$$= \text{proj}_b \vec{a} \quad * \quad \frac{\|a\| \cos \theta}{\|a\|} = \cos \theta$$

$$\therefore \|a\| \cos \theta = \frac{a^T b}{\|b\|}$$

$$\vec{a} = a^{\parallel b} + a^{\perp b}$$



[정사영]

$$a^{\parallel b} = \text{proj}_b \vec{a} = \underbrace{(\vec{a} \cdot \hat{b})}_{\text{스칼라}} \underbrace{\hat{b}}_{\text{단위 벡터}} = \underbrace{\left(\frac{a^T b}{\|b\|} \right)}_{\text{스칼라, 길이}} \underbrace{\frac{b}{\|b\|}}_{\text{벡터, 단위}}$$

$$* \|a\| \cos \theta = \frac{a^T b}{\|b\|}$$

$$\begin{aligned} a^T b &= \vec{a} \cdot \vec{b} = \|a\| \|b\| \cos \theta \\ &= \|b\| \text{proj}_b(a) \\ &= \|b\| a^{\parallel b} \end{aligned}$$

3.0 고급 선형대수

3.1 선형대수와 해석기하의 기초

9) 직선의 방정식

벡터 w 에 수직인 임의의 직선의 방정식 (w 활용!)

- 벡터 w 에 수직인 직선의 방정식을 구하라

- 그 직선과 원점사이의 거리를 구하라

$\|w\|$ 와 $\|w'\|$ 의 차이 확인

- 1) w 와 w' 의 관계
- 2) 직교성각 이용, 방정식 생성
- 3) $w \rightarrow w'$ 으로 확장

연습문제 3.1.10 풀기

10) 직선과 점사이 거리

- 벡터 w 에 수직인 직선과 x' 의 거리를 구하라

Q. 직선과 x' 의 거리 (길이)


① $w \perp x'$ 의 그림그리기 (큰 그림, 이해 목적)

② w 에 수직인 직선의 방정식 찾기

③ $x' \cdot w'$

④ $|x' \cdot w' - \|w'\|^2|$

연습문제 3.1.11 풀기



직선과 점(x')의 거리

① w 와 x' 사이 거리 (정사영)

$$* \|a\|b\| = a^T \frac{b}{\|b\|}$$

$$\|x'w\| = x'^T \frac{w}{\|w\|} = \frac{w^T}{\|w\|} x' \quad (x'^T w = w^T x')$$

② 직선과 x' 사이 거리

S

$$S = \left| \|x'w\| - \|w\| \right| = \left| \frac{w^T}{\|w\|} x' - \|w\| \right|$$

$$= \left| \frac{w^T x' - \|w\|^2}{\|w\|} \right| = \left| \frac{w^T x' - w_0}{\|w\|} \right|$$

1) 선형독립과 선형종속

- (데카르트 좌표계의 x 축과 y 축이 수직인 이유. 서로 직교여야 독립)

- 연습문제 3.2.3

2) 선형독립과 연립방정식

- 선형독립의 논리적 식 (3.2.13식) 벡터 x_1, x_2, \dots, x_N 이 선형독립이라는 것을 논리기호로 나타내면 다음과 같다.
- 선형종속의 대표적인 경우 (03.02 3page) $Xc = 0 \rightarrow c = 0$

1) 벡터의 갯수가 벡터의 차원보다 크면 선형종속

2) 값이 같은 벡터가 있으면 선형종속

3) 어떤 벡터가 다른 벡터의 조합이면 선형종속

3) 랭크

$\therefore C(A)$ 의 기저 벡터 갯수

- 랭크의 정의: 행렬 내 선형독립 벡터의 최대개수
- 열랭크와 행랭크는 항상 같다

- rank $A \leq \min(M, N)$ *A가 M,N행렬일 때 (03.02 4page)

- code) rank구하는 코드

4) 풀랭크

- 정의 $\text{rank } A = \text{min}(m, n)$ 이면, full rank
- Low-랭크 행렬

- 1랭크 행렬 : N차원 벡터x 1개를 이용해 만든 행렬

($n \times n$ 행렬은 사실 벡터 1개의 복제품)

- 2랭크 행렬 : N차원 벡터x 2개를 이용해 만든 행렬
- 3랭크 행렬 : N차원 벡터x 3개를 이용해 만든 행렬

- 랭크와 역행렬

- 정방행렬이 풀랭크면, 역행렬이 존재

(전단사함수 \leftrightarrow 역행렬 존재)

(rankA=N, rankA=M, M=N => 정방행렬, 풀랭크 조건 = 역행렬 조건)

(즉, 모두 선형독립인 열벡터만으로 이뤄진 정방행렬 \leftrightarrow 역행렬 존재)

(즉, 플랭크 정방행렬 \leftrightarrow 역행렬 존재)

선형동역 ← 연립방정식 풀 ← 해리분석 ○
종속 인종 ×

[illegible]


일부가 종속이면,
전체가 종속이다.

$x_1 \quad x_2 \quad x_3 \quad x_4 \quad x_5$

중속

중속

예) $\begin{array}{|c|} \hline x_1 \\ \hline \end{array} \begin{array}{|c|} \hline x_2 \\ \hline \end{array} \begin{array}{|c|} \hline x_3 \\ \hline \end{array}$ x_4 x_5 더미에 x_4, x_5 같은 걸 추가하면 선형 종속이 됨

5  행 랭크도

열 랭크 = 최대 3개 (\because 최대 3개)

~~X~~에 서형
중속이면
이렇게 하면 X?
[에 서형중속
이론만 채워져야
가능함]

03. 02 좌표와 변환 5) 벡터공간과 기저벡터


- 벡터공간 : 선형독립인 벡터 N개의 선형결합으로 만들어지는 집합

- 기저벡터 : 벡터공간을 이루는 선형독립인 벡터들

- 벡터공간의 차원 : 기저벡터의 갯수

(기저벡터 2개로는 2차원 column space 만들 수 있음)

ex) 만약, 선형독립인 3차원 벡터 2개가 주어졌다면,
2차원 column space는 만들 수 있지만,
3차원 column space는 만들 수 없다.



- 정리 : M차원 벡터 N개가 *선형독립* 일 때 (M x N 행렬) **full rank**
 - N = M => 모든 N차원 C(A) 생성 가능 (span of 벡터N개)
 - N > M => 갯수가 더 많음. N개 중 일부는 선형종속. 따라서, 선형종속이다.
 기저벡터 갯수만큼 차원의 열공간 생성

- N < M => 갯수가 더 적음. N차원 C(A)가능. (but, M차원 C(A)는 불가)

ex) 3차원 벡터 2개가 선형독립

=> 2차원 C(A) 가능. (but, 3차원 C(A)는 불가.)

Q. C(A)는
pivot variable
스칼라
갯수

6) 정사영 (shadow to 벡터공간)

- 정규직교인 기저벡터의 M차원 공간 정사영

(03.02 10page그림, 03.02 11page)

- 정사영 =

- 정사영 길이 =




그림 3.2.1 : 3차원 벡터를 2차원 벡터공간에 투영하는 예

만약 기저벡터 v_1, v_2, \dots, v_M 가 정규직교(orthonormal)이면 투영벡터 $x^{\parallel v}$ 는 각 기저벡터에 대한 내적값으로 표현된다.

$$x^{\parallel v} = (x \cdot \hat{v}_1) \hat{v}_1 + (x \cdot \hat{v}_2) \hat{v}_2 + \dots + (x \cdot \hat{v}_M) \hat{v}_M \quad (3.2.47)$$

그리고 투영벡터의 길이의 제곱은 각 기저벡터와의 내적의 제곱합이다.

$$\|x^{\parallel v}\|^2 = \sum_{i=1}^M (x \cdot \hat{v}_i)^2 \quad (3.2.48)$$

03. 02 좌표와 변환 7) 표준기저벡터

- e_1, e_2, \dots
- 좌표 : 기저벡터를 선형조합하여 그 벡터를 나타내기 위한 계수벡터를 의미

(03.02 12page)

$x e_1, e_2 \rightarrow$ 보통 표준기저벡터

$$\begin{bmatrix} x \\ y \end{bmatrix} = \underbrace{x}_{\text{좌표}} \underbrace{e_1}_{\text{기저}} + \underbrace{y}_{\text{좌표}} \underbrace{e_2}_{\text{기저}}$$

8) 변환행렬

- 역할 : 기저벡터의 변환, 회전 및 스케일 (03.02 17page, 03.02 19page)

원래의 기저벡터가 아닌 새로운 기저벡터가 있다고 하자. 이 새로운 기저벡터들의 기존 기저벡터에 대한 좌표를 열벡터로 보고 이를 행렬로 묶은 행렬 A 를 생각하자.

예를 들어, 기존의 기저벡터가 $\{e_1, e_2\}$ 이고 새로운 기저벡터 $\{g_1, g_2\}$ 간에 다음과 같은 관계가 성립한다면,

$$\begin{aligned} g_1 &= \frac{1}{\sqrt{2}}e_1 + \frac{1}{\sqrt{2}}e_2 \\ g_2 &= -\frac{1}{\sqrt{2}}e_1 + \frac{1}{\sqrt{2}}e_2 \end{aligned}$$

e_1, e_2 에 대한 g_1, g_2 의 좌표벡터는 다음처럼 열벡터로 나타낼 수 있다.

$$g_{1e} = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}, \quad g_{2e} = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

두 좌표벡터들을 합쳐서 행렬로 표시하면 다음과 같다.

$$\begin{bmatrix} g_1 & g_2 \end{bmatrix} = \begin{bmatrix} e_1 & e_2 \end{bmatrix} \begin{bmatrix} g_{1e} & g_{2e} \end{bmatrix} = \begin{bmatrix} e_1 & e_2 \end{bmatrix} A$$

$$A = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

$$\begin{aligned} \text{좌표} &= \begin{bmatrix} \text{---} \end{bmatrix} \text{좌표} \quad \Leftrightarrow \quad \vec{x}_e = A \vec{x}_g \\ \{g_1, g_2\} &= A^{-1} \{e_1, e_2\} \quad \Leftrightarrow \quad A^{-1} \vec{x}_e = \vec{x}_g \\ \vec{x}_g &= T(A^{-1}) \vec{x}_e \quad \Leftrightarrow \quad T \vec{x}_e = \vec{x}_g \end{aligned}$$

(3.2.59)

(3.2.60) $T(\text{변환 행렬})$ 의 역할 = 회전, 스케일


(3.2.61)

(3.2.62)


9) 이미지변환

- 03.02 23page
- 연습문제 3.2.9 (수기 및 코드 확인)

좌표변환전



좌표변환후



1) 고유값과 고유벡터

- 정의

정방 행렬 A 에 대해 다음 식을 만족하는 영벡터가 아닌 벡터 v , 실수 λ 를 찾을 수 있다고 가정하자.

$$Av = \lambda v \quad (3.3.1)$$

위 식을 만족하는 실수 λ 를 **고유값(eigenvalue)**, 벡터 v 를 **고유벡터(eigenvector)**라고 한다. 고유값과 고유벡터를 찾는 작업을 **고유분해(eigen-decomposition)** 또는 **고유값 분해(eigenvalue decomposition)**라고 한다.

- 고유값 분해는 정방행렬에서만 가능
- 행렬을 곱해서 변환 시, 방향은 변하지 않고 스케일링 효과만 있을 때 그때의 스케일러를 고유값, 방향을 고유벡터라고 한다.
- 대표적으로 고유벡터를 단위벡터로 상정해서 얘기한다.

2) 고유값 계산

- 특성방정식의 해 찾기 (03.03 2page)

행렬 A 의 고유값은 $A - \lambda I$ 의 행렬식이 0이 되도록 하는 **특성방정식(characteristic equation)**의 해를 구하면 된다.

$$\det(A - \lambda I) = 0 \quad (3.3.16)$$

[고유값 갯수]

- N차 정방행렬의 고유값은 항상 N개 (중근 및 복소수 모두 별개라고 가정 시)

1차 → 2차 변환. ∴ 2차원 각각을 Scaling 해주기 위해서,

[고유값과 trace, determinant]

당연히 고유값도 n개 있어야!

- $\text{tr}(A) = \text{고유값 합}$
- $\det(A) = \text{고유값 곱}$ *고유값 중 하나라도 존재하면, 역행렬이 존재하지 않는다.
($\det(A) = 0$ 이 되니까) *0이*

3) 고유벡터 계산

- 특성방정식에 고유값 넣어서 계산

03. 03 고유값 분해 4) 대각화

- 고유값 행렬 = diag(람다i)
- 정방행렬 A의 고유값분해 = 대각화 (03.03 8page)

고유벡터행렬 V은 고유벡터를 열벡터로 옆으로 쌓아서 만든 행렬이다.

$$V = [v_1 \cdots v_N] \quad (3.3.50)$$

$$V \in \mathbf{R}^{N \times N} \quad (3.3.51)$$

고유값행렬 Λ은 고유값을 대각성분으로 가지는 대각행렬이다.

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_N \end{bmatrix} \quad (3.3.52)$$

$$\Lambda \in \mathbf{R}^{N \times N} \quad (3.3.53)$$

위와 같이 고유벡터행렬과 고유값행렬을 정의하면 행렬과 고유벡터행렬의 곱은 고유벡터행렬과 고유값행렬의 곱과 같다.

$$\begin{aligned} AV &= A[v_1 \cdots v_N] \\ &= [Av_1 \cdots Av_N] \\ &= [\lambda_1 v_1 \cdots \lambda_N v_N] \\ &= [v_1 \cdots v_N] \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_N \end{bmatrix} \\ &= V\Lambda \end{aligned} \quad (3.3.54)$$

즉,

$$AV = V\Lambda \quad (3.3.55)$$

만약 고유벡터행렬 V의 역행렬이 존재한다면 행렬을 다음처럼 고유벡터행렬과 고유값행렬의 곱으로 표현할 수 있다. 이를 행렬의 대각화(diagonalization)라고 한다.

$$A = V\Lambda V^{-1} \quad (3.3.56)$$

5) 대각화 가능 조건

- full rank는 역행렬. 역행렬은 full rank
- 고유벡터행렬이 full rank. 선형독립 set이어야 한다.

03. 03 고유값 분해 6) 대칭행렬의 고유분해

선형독립
|
가짜행렬
|
직교?

직교하면
선형독립?

Ans)
직교되는 벡터
개수는
선형독립(2)

- 대칭행렬 => orthogonal 고유벡터행렬 + 실수 고유값 갖는다.
(고유값은 실수 + 고유벡터는 서로 직교)
- 대칭행렬은 항상 대각화가 가능함
(고유벡터 행렬이 full rank -> 고유벡터 행렬의 inverse 가능)

- 만약, 고유벡터들이 정규화된 상태라면
- 대칭행렬 => orthonormal 고유벡터행렬 + 실수 고유값 갖는다.
(고유값은 실수 + 고유벡터는 서로 정규직교)
- 고유벡터행렬 V 는 정규직교행렬... 따라서, $VV^T = I \iff V^{-1} = V^T$

- 대칭행렬의 고유분해 (03.03 11page)
(고유벡터들이 정규화된 정규직교벡터set 행렬 V)

대칭행렬에 대해서는 다음 정리가 성립한다.

[정리] 행렬 A 가 실수인 대칭행렬이면 고유값이 실수이고 고유벡터는 서로 직교(orthogonal)한다.

만약 고유벡터들이 크기가 1이 되도록 정규화된 상태라면 고유벡터 행렬 V 는 정규직교(orthonormal) 행렬이므로 전치행렬이 역행렬이다.

$$V^T V = V V^T = I \quad (3.3.68)$$

$$V^{-1} = V^T \quad (3.3.69)$$

따라서 대각화가 가능하고 다음처럼 쓸 수 있다.

$$A = V \Lambda V^T \quad (3.3.70)$$

이 사실로부터 다음 정리도 도출된다.

[정리] 실수인 대칭행렬은 항상 대각화가능하다.

7) 대칭행렬을 랭크-1 행렬의 합으로 분해 (03.03 12page) (매우 중요)

- 부분행렬 3번 case로 해석 (수기로 해보기) + 예제 풀이

N 차원 대칭행렬 A 는 다음처럼 N 개의 랭크-1 행렬 $A_i = v_i v_i^T$ 의 합으로 표시할 수 있다.

$$A = V \Lambda V^T$$

$$= \begin{bmatrix} v_1 & v_2 & \cdots & v_N \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_N \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_N^T \end{bmatrix} \quad (3.3.71)$$
$$= \begin{bmatrix} \lambda_1 v_1 & \lambda_2 v_2 & \cdots & \lambda_N v_N \end{bmatrix} \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_N^T \end{bmatrix}$$

따라서 N 차원 대칭행렬 A 는

$$A = \sum_{i=1}^N \lambda_i v_i v_i^T = \sum_{i=1}^N \lambda_i A_i = \lambda_1 A_1 + \cdots + \lambda_N A_N \quad (3.3.72)$$

8) 대칭행렬의 고유값 부호

- 대칭행렬이 양의정부호 \iff 고유값이 모두 양수 (매우 중요)
- 대칭행렬이 양의준정부호 \iff 고유값이 모두 양수 or 0
- 둘 다 증명 해보기(꼭 암기는 아니더라도, 해보기!)

* 부호 판별 $\left\{ \begin{array}{l} R^2 : \begin{pmatrix} a & b \\ b & c \end{pmatrix} \text{에서 } a > 0, ac > b^2 \text{ 일 때 양의 정부호} \\ R^n (n \geq 2) : f = x^T A x > 0 \text{ 이면, 양의 정부호} \quad / \quad \lambda_i > 0 \text{ 이면 } + \end{array} \right.$

진문
대칭행렬이
양의정부호라면
고유값이
양수?
(대칭행렬만
부호 판별!)


03.03 고유값 분해 9) 분산행렬

- 분산행렬 : $X^T X$ 인 정방행렬
- 분산행렬은 대칭행렬이다.
- 분산행렬은 양의정부호 + 고유값 ≥ 0
(분산행렬은 대칭행렬. 대칭행렬이 양의정부호이면, 고유값은 모두 양수)
- 분산행렬이 양의정부호 증명(꼭 해보기) *분산행렬은 항상 psd or semi-positive*

10) 분산행렬의 역행렬

- (03.03 17page)
- *X만 full rank라면, 역행렬 존재하지 않아도..
그것의 분산행렬인 $X^T X$ 의 역행렬이 존재한다는 것.

- X가 full rank가 아니라면, 분산행렬의 역행렬이 존재하지 않고
 \Rightarrow 최소제곱법($Ax = b$ 의 근사해 찾기 위한 수도인버스) 불가
(03.03 17page 하단부)



11) 고유분해의 성질 (03.03 18page)

요약: 고유분해의 성질

지금까지 나왔던 고유분해와 관련된 정리를 다시 한 번 요약하였다. 이 정리들은 데이터 분석에서 자주 사용되므로 잘 알아두자.

N 차원 정방행렬 A 에 대해

1. 행렬 A 는 N 개의 고유값-고유벡터를 가진다(복소수인 경우와 중복인 경우를 포함).
2. 행렬의 대각합은 모든 고유값의 합과 같다.
3. 행렬의 행렬식은 모든 고유값의 곱과 같다.
4. 행렬 A 가 대칭행렬이면 N 개의 실수 고유값을 가지며 고유벡터들이 서로 직교(orthogonal)이다.
5. 행렬 A 가 대칭행렬이고 고유값이 모두 양수이면 양의 정부호(positive-definite)이고 역행렬이 존재한다. 역도 성립한다.
6. 행렬 A 가 어떤 행렬 X 의 분산행렬 $X^T X$ 이면 0 또는 양의 고유값을 가진다.
7. 행렬 $X \in \mathbb{R}^{N \times M} (N \geq M)$ 가 풀랭크이면 분산행렬 $X^T X$ 은 역행렬이 존재한다.

\hookrightarrow 양의정부호!

고유값 분해



대칭 행렬



분산행렬

$$A = V \Lambda V^{-1}$$

[$A = \text{square}$
 $V = \text{고유벡터 set (0이 아닌)}$

$$A_{\text{sym}} = V \Lambda V^T$$

[A_{sym}
 $V = (\text{정규})\text{직교 고유벡터 set}$

$$X^T X = V \Lambda V^T$$

[$\frac{X^T X}{V} = \text{sym}$
 $V = (\text{정규})\text{직교}$

• $A_{\text{sym}} = \sum_i \lambda_i A_i$
($* A_i = V_i V_i^T$, rank-1 행렬)

• $X^T X$ 는 posi or semi-posi

V^{-1} • V^{-1} 존재 대각화 가능

V^{-1} • 항상 대각화 가능

• 항상 대각화 가능

($V = \text{orthonormal}$, 선형독립 고유벡터 집합!

\Rightarrow full rank, square \Rightarrow 역행렬 존재)

A^T • A 는 λ 중 0 없으면
역행렬 존재

A^T • A_{sym} 이 positive definite라면, $\lambda_i > 0 \Rightarrow A_{\text{sym}}$ 역행렬 존재
 $\therefore \lambda_i \geq 0 \Rightarrow X^T X$ 역행렬 존재 가능

X 가 full-rank 라면

• 정방행렬 (A)의
역행렬 $\text{loop} \dots$

• 대칭행렬 (A_{sym} or $X^T X$) 의
역행렬 $\text{loop} \dots$

full rank
 $\lambda_i \neq 0 \rightarrow D \neq 0$

A_{sym} if
 $X^T X$ $X = \text{full rank}$
양의 정부호 $\rightarrow \lambda_i > 0 \rightarrow D \neq 0$

Q. 대칭행렬에선, 양의 정부호라면, full-rank가 되나?
ans) $A_{\text{sym}} = \sum \lambda_i A_i$ (A_{sym} 은 rank-1 행렬의 합이니까 full-rank?)

SVD

$$A = U \Sigma V^T$$

• A = 직사각

U = 직교행렬 1
(선형독립)

V = 직교행렬 2
(선형독립)

Σ = 대각행렬
(특이값 행렬)

$\lambda_i = \sigma_i^2$
($A^T A$ 로 확인 가능)

• $U = A A^T$ 의
고윳벡터 set
(직교, 선형독립)

• $V = A^T A$ 의
고윳벡터 set
(직교, 선형독립)

• 만약, A 가 양의 정방행렬이면,
 $U \Lambda U^T = U \Sigma U^T$
(고윳분해 = 특이분해)

고윳분해

$$A = V \Lambda V^{-1}$$

A = 정방행렬

V = 고윳벡터 set

• V^{-1} 존재해야 대각화 가능

inverse 조건: square + full rank

$\therefore V^{-1}$ 존재하려면,
 V 가 full-rank 여야 역행렬
가능 (대각화 가능)

• V 가 full-rank
= 모든 열벡터 (고윳벡터)가
선형독립이어야!
즉, 기저벡터 가능해야!
(선형독립이어서...)

고윳분해 (대칭)

$$A = U \Lambda U^T$$

A = 대칭행렬

V = 고윳벡터 set

(정규) 직교, 선형독립
실수 고윳값

• $V^T V = I$

• A_{sym} 이,
positive def-이면,
 $\lambda_i > 0$, inverse 가능

(물론, A_{sym} 이
posi-def 가 아니면,
 $\lambda_i < 0$)

고윳분해 (분산)

$$A^T A = V \Lambda V^T$$

$A^T A$ = 분산행렬

V = 고윳벡터 set

(정규) 직교, 선형독립
실수 고윳값

• $A^T A$ 는 항상
 $\lambda_i \geq 0$

• A 가 full-rank
라면,
 $A^T A$
positive def
 $\lambda_i > 0$
역행렬 존재

대칭행렬: 실수 고윳값

양의정방행렬: 양의 실수 고윳값
(대칭행렬 중 일부, 분산행렬)

03. 04 특이값 분해 1) 특이값과 특이벡터 (03.04 1page)

$N \times M$ 크기의 행렬 A 를 다음과 같은 3개의 행렬의 곱으로 나타내는 것을 특이분해(singular-decomposition) 또는 특이값 분해(singular value decomposition)라고 한다.

$$A = U \Sigma V^T \tag{3.4.1}$$

여기에서 U, Σ, V 는 다음 조건을 만족해야 한다.

- 대각성분이 양수인 대각행렬이어야 한다. 큰 수부터 작은 수 순서로 배열한다.

$$\Sigma \in \mathbf{R}^{N \times M} \tag{3.4.2}$$

- U 는 N 차원 정방행렬로 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$U \in \mathbf{R}^{N \times N} \tag{3.4.3}$$

- V 는 M 차원 정방행렬로 모든 열벡터가 단위벡터이고 서로 직교해야 한다.

$$V \in \mathbf{R}^{M \times M} \tag{3.4.4}$$

위 조건을 만족하는 행렬 Σ 의 대각성분들을 특이값(singular value), 행렬 U 의 열벡터들을 왼쪽 특이벡터(left singular vector), 행렬 V 의 행벡터들을 오른쪽 특이벡터(right singular vector)라고 부른다.


[정리] 특이분해는 모든 행렬에 대해 가능하다. 즉 어떤 행렬이 주어지더라도 위와 같이 특이분해할 수 있다.

2) 특이값 분해 행렬의 크기 (03.04 3page)


- 특이값 분해는 모든 행렬에 대해 가능하다.

(고유값 분해는 정방행렬A에 대해 + 고유벡터set이 가역적일 때만 대각화 가능)

행렬의 크기만 표시하면 다음과 같다.



또는



3) 특이값 분해의 축소형 (03.04 3page)

예제

행렬 A

3×2


$$A = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \tag{3.4.9}$$

는 다음처럼 특이분해할 수 있다.

3×3 3×2 3×2 2×2 2×2

$$A = \begin{bmatrix} -\frac{1}{\sqrt{6}} & \frac{2}{\sqrt{3}} & -\frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{6}} & -\frac{1}{\sqrt{3}} & -\frac{2}{\sqrt{30}} \\ -\frac{1}{\sqrt{6}} & 0 & \frac{5}{\sqrt{30}} \end{bmatrix} \begin{bmatrix} \sqrt{12} & 0 \\ 0 & \sqrt{10} \\ 0 & 0 \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \tag{3.4.10}$$

특이값 분해의 축소형



특이값 대각행렬에서 0인 부분은 사실상 아무런 의미가 없기 때문에 대각행렬의 0 원소 부분과 이에 대응하는 왼쪽(혹은 오른쪽) 특이벡터들을 없애고 다음처럼 축소된 형태로 해도 마찬가지로 원래 행렬이 나온다.

N 이 M 보다 큰 경우에는 왼쪽 특이벡터 중에서 u_{M+1}, \dots, u_N 을 없앤다.

$$A = \begin{bmatrix} | & | & | \\ u_1 & u_2 & \dots & u_M \\ | & | & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & 0 & \dots & 0 \\ 0 & 0 & \sigma_3 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \sigma_M \end{bmatrix} \begin{bmatrix} | \\ v_1^T \\ | \\ v_2^T \\ | \\ \vdots \\ | \\ v_M^T \end{bmatrix}$$

N 이 M 보다 작은 경우에는 오른쪽 특이벡터 중에서 v_{N+1}, \dots, v_M 을 없앤다.

$$A = \begin{bmatrix} | & | & | \\ u_1 & u_2 & \dots & u_N \\ | & | & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & 0 & \dots & 0 \\ 0 & 0 & \sigma_3 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \sigma_N \end{bmatrix} \begin{bmatrix} | \\ v_1^T \\ | \\ v_2^T \\ | \\ \vdots \\ | \\ v_N^T \end{bmatrix}$$

03. 04 특이값 분해 4) 파이썬을 활용한 특이분해(꼭 해보기) (연습문제 3.4.1)

5) 특이값과 특이벡터의 관계 (03.04 7page)

즉, i 번째 특이값 σ_i 와 특이벡터 u_i, v_i 는 다음과 같은 관계가 있다.

$$Av_i = \sigma_i u_i \quad (i = 1, \dots, \min(M, N))$$

이 관계는 고유분해와 비슷하지만 고유분해와는 달리 좌변과 우변의 벡터가 다르다.

고유분해

$$A = V \Lambda V^T$$

$$AV = V \Lambda$$

$$AV_i = \lambda_i v_i$$

특이분해

$$A = U \Sigma V^T$$

$$AV = U \Sigma$$

$$AV_i = \sigma_i u_i$$

6) 특이분해와 고유분해의 관계

이분행렬 $A = U \Sigma V^T, \Rightarrow$ 분산행렬화 $A^T A = (U \Sigma V^T)^T (U \Sigma V^T)$
 $= V \Sigma^T V^T U \Sigma V^T$
 $= V \Sigma^2 V^T$ 고유분해

특이 분해한 A 는 분산행렬화하면,

$$\lambda_i = \sigma_i^2 \text{ 인 고유분해가 된다.}$$


$$(A^T A = \underbrace{V \Sigma^2 V^T}_{\text{고유분해}} = \underbrace{V \Lambda V^T}_{\text{고유분해}})$$

7) 1차원 근사

- (03.04 10page, 11page)

1차원 근사

2차원 평면 위에 3개의 2차원 벡터 a_1, a_2, a_3 가 있다. 원점을 지나면서 모든 점들과 가능한 한 가까이 있는 직선을 만들고 싶다면 직선의 방향을 어떻게 해야 할까? 직선의 방향을 나타내는 단위 벡터를 w 라고 하자.



벡터 w 와 점 a_i 의 거리의 제곱은 다음처럼 계산할 수 있다.(연습 문제 3.1.9)

$$\|a_i^\perp w\|^2 = \|a_i\|^2 - \|a_i^\parallel w\|^2 = \|a_i\|^2 - (a_i^T w)^2 \quad (3.4.34)$$

벡터 a_1, a_2, a_3 를 행벡터로 가지는 행렬 A 를 가정하면

$$A = \begin{bmatrix} a_1^T \\ a_2^T \\ a_3^T \end{bmatrix} \quad (3.4.35)$$

행벡터의 놈의 제곱의 합은 행렬의 놈이므로 모든 점들과의 거리의 제곱의 합은 행렬의 놈으로 계산된다. (연습 문제 2.3.2)

$$\begin{aligned} \sum_{i=1}^3 \|a_i^\perp w\|^2 &= \sum_{i=1}^3 \|a_i\|^2 - \sum_{i=1}^3 (a_i^T w)^2 \\ &= \|A\|^2 - \|Aw\|^2 \end{aligned} \quad (3.4.36)$$

점 a_i 의 위치가 고정되어 있으므로 행렬 A 의 놈 값은 고정되어 있다. 따라서 이 값이 가장 작아지려면 $\|Aw\|^2$ 의 값이 가장 크게 만드는 w 를 찾아야 한다. 이 문제는 다음처럼 수식으로 쓸 수 있다.

$$\arg \max_w \|Aw\|^2 \quad (3.4.37)$$

* 분산행렬 $[A][B]$

$$① \equiv [B] = \begin{bmatrix} -a_1^T B - \\ -a_n^T B - \end{bmatrix}$$

$$② [A][I] = [A_1 \dots A_n]$$

$$③ [I][I] \equiv 1 + 1 + \dots \text{ 스칼라 곱셈}$$

$$* \sum (a_i^T w)^2 = \|Aw\|^2$$

$$\cdot \begin{bmatrix} a_1^T \\ -a_2^T \\ -a_3^T \end{bmatrix} w = \begin{bmatrix} a_1^T w \\ a_2^T w \\ a_3^T w \end{bmatrix}$$

$$\cdot \|Aw\| = \sqrt{(a_1^T w)^2 + \dots + (a_3^T w)^2}$$

$$\|Aw\|^2 = (a_1^T w)^2 + \dots + (a_3^T w)^2 = \sum (a_i^T w)^2$$