

분류 모형 [확률 [^{생성} 판별 \Rightarrow 로지스틱 회귀]
 판별]

[확률적 판별 모형]

$\hat{y} = 0$ or 1 | 분류하고자 할 때, $P(y|x)$ 값을 "베이지 정리가 아닌" x 의 함수값으로 가정. 판별함수를 찾아 데이터 x_{new} 를

0 or 1 로 분류하는 방법을

ex) $f(x) = \text{판별식}$

$f(x) = 0 \iff$ 인 x 집합은 경계선

$f(x) > 0 \iff$ 인 x 집합은 클래스 1
 데이터 $\hat{y} = 1$

$f(x) < 0 \iff$ 인 x 집합은 클래스 0
 데이터 $\hat{y} = 0$

[로지스틱 회귀 모형]

① 일단, 이진분류 ($\hat{y} = 0$ or 1 만 고려)

② y 는 이진 클래스 값. 베르누이 확률 분포를 따른다
 로지스틱 회귀모형에서, 이러한 y 를 연속치로 가정.

$$y \sim \text{Bern}(y; \mu(x))$$

$$y \sim \text{Bern}(y; w^T x) = \text{Bern}(y; \mu(x; w))$$

\hat{y} (측정값) $\div E[y] = \mu(x; w) = x$ 에 대한 함수

* Regression 예선, $\hat{y} = \mu = E[y] = w^T x$
 (지금은 \hat{y} 는 0 or 1 로 이진분류?)

* 기대값 = 모수 = $\mu(x; w) = w^T x =$ 독립 변수 x 의 선형결합
 \div 확률론적 선형회귀

* x (데이터)는 주어졌고, y 분포 (Bern)의 모수는 ' w '이다.

$$(3) y \sim \text{Bern}(y; \mu(x; w)) = \mu(x; w)^y (1 - \mu)^{1-y}$$

$$\left[\begin{array}{ll} \hat{y} \doteq E[y] = \mu(x; w) > 0.5 \text{ 라면,} & \hat{y} = 1 \\ \quad \quad \quad \quad \quad \quad \quad \quad < 0.5 & \hat{y} = 0 \\ \quad \quad \quad \quad \quad \quad \quad \quad = 0.5 & \text{경계선} \end{array} \right.$$

" $W^T x = 0.5$ " 일 때의
 z 값 (직선, 선형결합)

$$(4) \text{로지스틱 회귀모형의 분포 "판별식"} \\ = \mu(x; w) = W^T x \\ \therefore \mu(x; w) = W^T x \text{ 를 찾아야 한다.}$$

시그모이드!
 를 위아래
 만들기!

$$(5) \mu(x; w) = W^T x \Rightarrow \mu(x; w) = \sigma(W^T x)$$

시그모이드 함수
 [로지스틱
 하이퍼볼릭 탄젠트
 다이나]

* $\mu(x; w)$ 는 베르누이분포의 기대값이라 "확률값"
 $W^T x$ 는 $-\infty < \infty$ \Rightarrow $0 \leq \leq 1$

$$\therefore \sigma(W^T x) \text{ 는 } 0 < < 1$$

$$\mu(x; w) \neq W^T x$$

$$\mu(x; w) = \sigma(W^T x) = \sigma(z)$$

$$* \sigma = \text{시그모이드 함수 (대부분이 로지스틱)}, \sigma(z) = \frac{1}{1 + e^{-z}} \\ (= S\text{-like})$$

$$(6) \text{로지스틱 회귀모형의 분포 "판별식"} \\ \Rightarrow \text{기값에 따라 판별식 값 결정}$$

$$\left[\begin{array}{llll} W^T x = z = 0 & \Rightarrow & \sigma(z) = \mu = \frac{1}{2} & \text{경계선} \\ & & & \\ & > 0 & \Rightarrow & > \frac{1}{2} \quad \hat{y} = 1 \\ & < 0 & \Rightarrow & < \frac{1}{2} \quad \hat{y} = 0 \end{array} \right.$$

이제
 $\mu(w)$ 찾아야함
 입력된 데이터

[로지스틱 회귀 분석 모형]

⑦ 문제는 $x \xrightarrow{w} z$ w 가 결정되지 않음!
(판별 모델 자체가 아직...)

$w^T x$ 의 모수(w)를 MLE로 추정.

* MLE : y 의 가능성을 maximize 하는
 $L(\mu; y)$ 시각 (모수, 분포) 찾기
= 확률분포 찾기

< MLE >

$$L(\theta; x_1, \dots, x_n)$$

$$= p(x_1, \dots, x_n; \theta)$$

변수

모수 (상수로 가정)
= 분포

$$p(y|x) = pdf = p(y; \mu) = \mu^y (1-\mu)^{1-y}$$

\Leftrightarrow
의미상으로는

μ 가 정해졌을 때,
 y 값 = 확률값

$$\mu_0^y (1-\mu_0)^{1-y}$$

$$L(\mu; y) = \mu^y (1-\mu)^{1-y}$$

\Leftrightarrow

y 가 정해졌을 때
(전라가 정해짐)
 μ 값 = 가능성

$$\mu_0^y (1-\mu_0)^{1-y}$$

μ
어느 분포에서

가능도 \uparrow ?

(= 이 전라값일 때,
 y)

가장 많은 μ 는 무엇인가?

$$= \arg \max_{\mu} L(\mu; y)$$

$$* \mu = \mu(x; w)$$

$$⑧ L(\mu(x; w); y) = \mu^y (1-\mu)^{1-y}$$

$$⑨ L \rightarrow LL \rightarrow \frac{\partial LL}{\partial w} \Leftrightarrow y \text{를 배틀란}$$

x, y 가 모두 벡터 데이터

가장 가능성 높은 분포 찾기

x 는 관측 확률변수에서 나온 데이터 (벡터형)이므로 독립

(모수 μ ,
 w 는 일종의
하이퍼 모수)

$\therefore L \rightarrow$ 다변수함수로 변환 $\rightarrow LL$ (로그가능도 함수화)

$$\textcircled{10} \quad \frac{\partial LL}{\partial w} = 0 \quad \text{으로 만드는 } w \text{ 찾기}$$

$$\text{---} = J = \text{그래디언트 벡터}$$

$$= \text{미분형} \dots \text{why?}$$

$$a(x; w) = \sigma(w^T x)$$

$$= \text{미분형} \dots$$

\therefore 수치적 최적화로 w 값 찾기.

"최적화 $\Leftrightarrow J = 0$ 인 w 찾기"

[속도인 베스
수치적 최적화

$\textcircled{11}$ 수치적 최적화

< SGD >


$$\begin{aligned} w_{k+1} &= w_k - \eta \times J \\ &= w_k - \eta \times \frac{\partial LL}{\partial w} \end{aligned}$$

결국은...



$\textcircled{12}$ w 값 찾기 \Leftrightarrow 모델 찾기 (포인팅식!)




찾은 모델로 x_{test} 넣어서



$$w^T x = z \quad \text{vs} \quad 0$$



$$\sigma(z) \quad \text{vs} \quad \frac{1}{2}$$



$$\hat{y} = ?$$

[로지스틱 회귀 | 성능 측정]

$$R^2_{\text{suedo}} = \log \text{loss} \text{ 이용한 맥파든 } R^2 \quad \left(\begin{array}{l} \text{worst} = R^2_{\text{suedo}} = 0 \\ \text{best} = R^2_{\text{suedo}} = 1 \end{array} \right)$$

로지스틱 회귀 성능은 맥파든 의사결정계수(McFadden pseudo R square)값으로 측정한다.

$$R^2_{\text{suedo}} = \log \text{loss} \text{를 이용한 맥파든 } R^2 \quad R^2_{\text{pseudo}} = 1 - \frac{G^2}{G_0^2} \quad \begin{array}{l} \text{worst: } R^2_{\text{suedo}} = 0 \\ \text{best: } R^2_{\text{suedo}} = 1 \end{array}$$

G^2 는 이탈도(deviance)라고 하는 양으로 다음과 같이 정의된다.

$$G^2 = 2 \sum_{i=1}^N \left(y_i \log \frac{y_i}{\hat{y}_i} + (1 - y_i) \log \frac{1 - y_i}{1 - \hat{y}_i} \right) \Rightarrow \log \text{loss} \text{ class entropy와 부호만 다름}$$

여기에서 \hat{y} 는 $y = 1$ 일 확률 μ 를 뜻한다.

$$\hat{y} = y = \mu = 1$$

$$\hat{y}_i = \mu(x_i)$$

이탈도는 모형이 100% 정확한 경우에는 0이 되고 모형의 성능이 나빠질수록 값이 커진다. 부정확할수록 0보다 커진다.

또한 이탈도는 로그 가능도에 음수를 취한 값과 같다.

$$G^2 = -LL$$

* Null model
= 가장 쓸모없는 모델 = 귀무모델
= random model
= x이 상관이 없이 y 예측하는 모델

G^2 는 현재 이탈도이고 G_0^2 는 귀무모형(null model)으로 측정한 이탈도다.

귀무이탈도

귀무모형이란 모든 x 가 y 를 예측하는데 전혀 영향을 미치지 않는 모형을 말한다. 즉, 무조건부 확률 $p(y)$ 에 따라 x 에 상관없이 동일하게 y 를 예측하는 모형을 말한다. 결국 우리가 만들 수 있는 가장 성능이 나쁜 모형이 된다. (결과값)

$$\mu_{\text{null}} = \frac{\text{number of } Y = 1 \text{ data}}{\text{number of all data}} = \text{단순히 } y \text{의 개수에 따라 } \mu \text{ 측정}$$

자라 무개념이든 0이 | (데이터 개수 많은 쪽)

따라서 맥파든 의사결정계수는 가장 성능이 좋을 때는 1이 되고 가장 성능이 나쁠 때는 0이 된다.

$$G^2 \text{이 가진수 있는 가장 나쁜 성능 모델의 값} = G_0^2 \therefore \text{가장 나쁜 모델의 } R^2_{\text{suedo}} = 1 - 1 = 0$$