모형 최적화

머신 러닝 모형이 완성된 후에는 최적화 과정을 통해 예측 성능을 향상시킨다.

Scikit-Learn 의 모형 하이퍼 파라미터 튜닝 도구

Scikit-Learn에서는 다음과 같은 모형 최적화 도구를 지원한다.

- validation_curve_(http://scikitlearn.org/stable/modules/generated/sklearn.model_selection.validation_curve.html)
 - 단일 하이퍼 파라미터 최적화
- GridSearchCV (http://scikit-

learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html)

- 그리드를 사용한 복수 하이퍼 파라미터 최적화
- <u>ParameterGrid</u> (http://scikitlearn.org/stable/modules/generated/sklearn.model_selection.ParameterGrid.html)
 - 복수 파라미터 최적화용 그리드

validation_curve

validation_curve 함수는 최적화할 파라미터 이름과 범위, 그리고 성능 기준을 param_name , param_range , scoring 인수로 받아 파라미터 범위의 모든 경우에 대해 성능 기준을 계산한다.

In [1]:

```
from sklearn.datasets import load_digits
from sklearn.svm import SVC
from sklearn.model_selection import validation_curve

digits = load_digits()
X, y = digits.data, digits.target

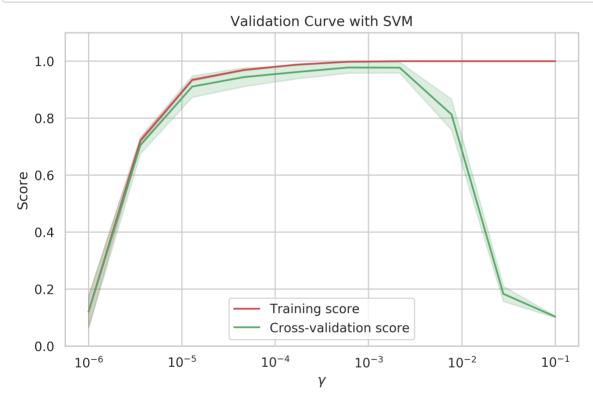
param_range = np.logspace(-6, -1, 10)
```

In [2]:

```
CPU times: user 50.7 s, sys: 0 ns, total: 50.7 s Wall time: 50.7 s
```

In [3]:

```
train scores mean = np.mean(train scores, axis=1)
train_scores_std = np.std(train_scores, axis=1)
test scores mean = np.mean(test scores, axis=1)
test scores std = np.std(test scores, axis=1)
mpl.rcParams["font.family"] = 'DejaVu Sans'
plt.semilogx(param range, train scores mean, label="Training score", color="r")
plt.fill between(param range, train scores mean - train scores std,
                 train scores mean + train scores std, alpha=0.2, color="r")
plt.semilogx(param range, test scores mean,
             label="Cross-validation score", color="g")
plt.fill between(param range, test scores mean - test scores std,
                 test_scores_mean + test_scores_std, alpha=0.2, color="g")
plt.legend(loc="best")
plt.title("Validation Curve with SVM")
plt.xlabel("$\gamma$")
plt.ylabel("Score")
plt.ylim(0.0, 1.1)
plt.show()
```



GridSearchCV

GridSearchCV 클래스는 validation_curve 함수와 달리 모형 래퍼(Wrapper) 성격의 클래스이다. 클래스 객체에 fit 메서드를 호출하면 grid search를 사용하여 자동으로 복수개의 내부 모형을 생성하고 이를 모두 실행시켜서 최적 파라미터를 찾아준다. 생성된 복수개와 내부 모형과 실행 결과는 다음 속성에 저장된다.

- grid scores
 - param grid 의 모든 파리미터 조합에 대한 성능 결과. 각각의 원소는 다음 요소로 이루어진 튜플이다.
 - parameters: 사용된 파라미터
 - mean validation score: 교차 검증(cross-validation) 결과의 평균값
 - cv validation scores: 모든 교차 검증(cross-validation) 결과
- best score
 - 최고 점수
- best params
 - 최고 점수를 낸 파라미터
- best estimator
 - 최고 점수를 낸 파라미터를 가진 모형

In [4]:

CPU times: user 6min 26s, sys: 600 ms, total: 6min 27s Wall time: 6min 27s

/home/dockeruser/anaconda3/lib/python3.6/site-packages/sklearn/model _selection/_search.py:841: DeprecationWarning: The default of the `i id` parameter will change from True to False in version 0.22 and wil l be removed in 0.24. This will change numeric results when test-set sizes are unequal.

DeprecationWarning)

```
In [5]:
```

gs.cv_results_["params"]

Out[5]:

```
[{'clf C': 0.0001, 'clf kernel': 'linear'},
{'clf_C': 0.001, 'clf_kernel': 'linear'},
{'clf_C': 0.01, 'clf_kernel': 'linear'},
{'clf C': 0.1, 'clf kernel': 'linear'},
{'clf_C': 1.0, 'clf_kernel': 'linear'},
{'clf C': 10.0, 'clf kernel': 'linear'},
 {'clf C': 100.0, 'clf kernel': 'linear'},
 {'clf C': 1000.0, 'clf kernel': 'linear'},
 {'clf_C': 0.0001, 'clf_gamma': 0.0001, 'clf_kernel': 'rbf'},
 {'clf_C': 0.0001, 'clf_gamma': 0.001, 'clf_kernel': 'rbf'},
 {'clf_C': 0.0001, 'clf_gamma': 0.01, 'clf_kernel': 'rbf'},
{'clf_C': 0.0001, 'clf_gamma': 0.1, 'clf_kernel': 'rbf'},
{'clf__C': 0.0001, 'clf__gamma': 1.0, 'clf__kernel': 'rbf'},
 {'clf C': 0.0001, 'clf gamma': 10.0, 'clf_kernel': 'rbf'},
 {'clf C': 0.0001, 'clf gamma': 100.0, 'clf kernel': 'rbf'},
{'clf_C': 0.0001, 'clf_gamma': 1000.0, 'clf_kernel': 'rbf'},
 {'clf C': 0.001, 'clf gamma': 0.0001, 'clf kernel': 'rbf'},
 {'clf__C': 0.001, 'clf__gamma': 0.001, 'clf__kernel': 'rbf'},
{'clf_C': 0.001, 'clf_gamma': 0.01, 'clf_kernel': 'rbf'}, {'clf_C': 0.001, 'clf_gamma': 0.1, 'clf_kernel': 'rbf'},
 {'clf C': 0.001, 'clf gamma': 1.0, 'clf kernel': 'rbf'},
 {'clf_C': 0.001, 'clf_gamma': 10.0, 'clf_kernel': 'rbf'},
{'clf_C': 0.001, 'clf_gamma': 100.0, 'clf_kernel': 'rbf'},
{'clf_C': 0.001, 'clf_gamma': 1000.0, 'clf_kernel': 'rbf'},
 {'clf__C': 0.01, 'clf__gamma': 0.0001, 'clf__kernel': 'rbf'},
{'clf_C': 0.01, 'clf_gamma': 0.001, 'clf_kernel': 'rbf'}, {'clf_C': 0.01, 'clf_gamma': 0.01, 'clf_kernel': 'rbf'},
 {'clf_C': 0.01, 'clf_gamma': 0.1, 'clf_kernel': 'rbf'},
 {'clf C': 0.01, 'clf gamma': 1.0, 'clf kernel': 'rbf'},
{'clf_C': 0.01, 'clf_gamma': 10.0, 'clf_kernel': 'rbf'}, {'clf_C': 0.01, 'clf_gamma': 100.0, 'clf_kernel': 'rbf'},
 {'clf C': 0.01, 'clf gamma': 1000.0, 'clf_kernel': 'rbf'},
{'clf C': 0.1, 'clf gamma': 0.0001, 'clf kernel': 'rbf'},
{'clf_C': 0.1, 'clf_gamma': 0.001, 'clf_kernel': 'rbf'},
{'clf__C': 0.1, 'clf__gamma': 0.01, 'clf__kernel': 'rbf'},
 {'clf_C': 0.1, 'clf_gamma': 0.1, 'clf kernel': 'rbf'},
{'clf_C': 0.1, 'clf_gamma': 1.0, 'clf_kernel': 'rbf'}, {'clf_C': 0.1, 'clf_gamma': 10.0, 'clf_kernel': 'rbf'},
 {'clf C': 0.1, 'clf gamma': 100.0, 'clf kernel': 'rbf'},
 {'clf C': 0.1, 'clf gamma': 1000.0, 'clf kernel': 'rbf'},
{'clf_C': 1.0, 'clf_gamma': 0.0001, 'clf_kernel': 'rbf'}, {'clf_C': 1.0, 'clf_gamma': 0.001, 'clf_kernel': 'rbf'},
 {'clf_C': 1.0, 'clf_gamma': 0.01, 'clf_kernel': 'rbf'},
 {'clf C': 1.0, 'clf gamma': 0.1, 'clf kernel': 'rbf'},
{'clf_C': 1.0, 'clf_gamma': 1.0, 'clf_kernel': 'rbf'}, {'clf_C': 1.0, 'clf_gamma': 10.0, 'clf_kernel': 'rbf'},
 {'clf C': 1.0, 'clf gamma': 100.0, 'clf kernel': 'rbf'},
{'clf_C': 1.0, 'clf_gamma': 1000.0, 'clf_kernel': 'rbf'}, {'clf_C': 10.0, 'clf_gamma': 0.0001, 'clf_kernel': 'rbf'},
 {'clf C': 10.0, 'clf gamma': 0.001, 'clf kernel': 'rbf'},
 {'clf C': 10.0, 'clf gamma': 0.01, 'clf kernel': 'rbf'},
{'clf_C': 10.0, 'clf_gamma': 0.1, 'clf_kernel': 'rbf'},
{'clf_C': 10.0, 'clf_gamma': 1.0, 'clf_kernel': 'rbf'},
 {'clf C': 10.0, 'clf gamma': 10.0, 'clf kernel': 'rbf'},
{'clf_C': 10.0, 'clf_gamma': 100.0, 'clf_kernel': 'rbf'}, 
{'clf_C': 10.0, 'clf_gamma': 1000.0, 'clf_kernel': 'rbf'}, 
{'clf_C': 100.0, 'clf_gamma': 0.0001, 'clf_kernel': 'rbf'},
 {'clf_C': 100.0, 'clf_gamma': 0.001, 'clf_kernel': 'rbf'},
 {'clf_C': 100.0, 'clf_gamma': 0.01, 'clf_kernel': 'rbf'},
```

```
{'clf C': 100.0, 'clf gamma': 0.1, 'clf kernel': 'rbf'},
 {'clf C': 100.0, 'clf qamma': 1.0, 'clf kernel': 'rbf'},
 {'clf C': 100.0, 'clf gamma': 10.0, 'clf kernel': 'rbf'},
 {'clf_C': 100.0, 'clf_gamma': 100.0, 'clf_kernel': 'rbf'},
 {'clf C': 100.0, 'clf gamma': 1000.0, 'clf kernel': 'rbf'},
 {'clf C': 1000.0, 'clf gamma': 0.0001, 'clf kernel': 'rbf'},
 {'clf_C': 1000.0, 'clf_gamma': 0.001, 'clf_kernel': 'rbf'},
 {'clf C': 1000.0, 'clf gamma': 0.01, 'clf kernel': 'rbf'},
 {'clf C': 1000.0, 'clf gamma': 0.1, 'clf kernel': 'rbf'},
 {'clf C': 1000.0, 'clf gamma': 1.0, 'clf kernel': 'rbf'},
 {'clf_C': 1000.0, 'clf_gamma': 10.0, 'clf_kernel': 'rbf'},
 {'clf C': 1000.0, 'clf gamma': 100.0, 'clf kernel': 'rbf'},
 {'clf C': 1000.0, 'clf gamma': 1000.0, 'clf kernel': 'rbf'}]
In [6]:
gs.cv results ["mean test score"]
Out[6]:
array([0.20868114, 0.91819699, 0.95269894, 0.95826377, 0.95826377,
       0.95826377, 0.95826377, 0.95826377, 0.11908737, 0.12020033,
       0.1213133 , 0.10350584, 0.10127991, 0.11185309, 0.10183639,
       0.10127991, 0.11908737, 0.12020033, 0.1213133 , 0.10350584,
       0.10127991, 0.11185309, 0.10183639, 0.10127991, 0.11908737,
       0.12020033, 0.13967724, 0.10350584, 0.10127991, 0.11185309,
       0.10183639, 0.10127991, 0.11908737, 0.68614357, 0.91207568,
       0.40567613, 0.10127991, 0.11185309, 0.10183639, 0.10127991,
       0.70339455, 0.93266555, 0.9638286 , 0.90984975, 0.11908737,
       0.10127991, 0.10127991, 0.10127991, 0.934335 , 0.95659432,
       0.97161937, 0.9115192 , 0.12966055, 0.10127991, 0.10127991,
       0.10127991, 0.95548136, 0.96160267, 0.97161937, 0.9115192 ,
       0.12966055, 0.10127991, 0.10127991, 0.10127991, 0.95993322,
      0.96215915, 0.97161937, 0.9115192 , 0.12966055, 0.10127991,
      0.10127991, 0.101279911)
In [7]:
print(gs.best score )
print(gs.best params )
0.9716193656093489
```

```
{'clf C': 10.0, 'clf gamma': 0.01, 'clf kernel': 'rbf'}
```

ParameterGrid

때로는 scikit-learn 이 제공하는 GridSearchCV 이외의 방법으로 그리드 탐색을 해야하는 경우도 있다. 이 경우 파라미터를 조합하여 탐색 그리드를 생성해 주는 명령어가 ParameterGrid 이다. ParameterGrid 는 탐색을 위한 iterator 역 할을 한다.

```
In [8]:
```

```
from sklearn.model selection import ParameterGrid
```

```
In [9]:
```

병렬 처리

GridSearchCV 명령에는 n_{jobs} 라는 인수가 있다. 디폴트 값은 1인데 이 값을 증가시키면 내부적으로 멀티 프로세스를 사용하여 그리드서치를 수행한다. 만약 CPU 코어의 수가 충분하다면 n_{jobs} 를 늘릴 수록 속도가 증가한다.

In [11]:

```
In [12]:
```

```
%%time
gs1.fit(X, y)
CPU times: user 21.2 s, sys: 10 ms, total: 21.3 s
Wall time: 21.3 s
/home/dockeruser/anaconda3/lib/python3.6/site-packages/sklearn/model
selection/ search.py:841: DeprecationWarning: The default of the `i
id parameter will change from True to False in version 0.22 and wil
1 be removed in 0.24. This will change numeric results when test-set
sizes are unequal.
  DeprecationWarning)
Out[12]:
GridSearchCV(cv=5, error score='raise-deprecating',
       estimator=SVC(C=1.0, cache size=200, class weight=None, coef0
=0.0,
  decision function shape='ovr', degree=3, gamma='auto deprecated',
  kernel='rbf', max iter=-1, probability=False, random state=None,
  shrinking=True, tol=0.001, verbose=False),
       fit params=None, iid='warn', n jobs=1,
       param grid={'gamma': array([1.00000e-06, 3.59381e-06, 1.29155
e-05, 4.64159e-05, 1.66810e-04,
       5.99484e-04, 2.15443e-03, 7.74264e-03, 2.78256e-02, 1.00000e-
01])},
       pre dispatch='2*n jobs', refit=True, return_train_score='war
n',
       scoring='accuracy', verbose=0)
```

```
In [13]:
```

```
%%time
gs2.fit(X, y)
CPU times: user 200 ms, sys: 80 ms, total: 280 ms
Wall time: 12.1 s
/home/dockeruser/anaconda3/lib/python3.6/site-packages/sklearn/model
_selection/_search.py:841: DeprecationWarning: The default of the `i
id parameter will change from True to False in version 0.22 and wil
1 be removed in 0.24. This will change numeric results when test-set
sizes are unequal.
  DeprecationWarning)
Out[13]:
GridSearchCV(cv=5, error score='raise-deprecating',
       estimator=SVC(C=1.0, cache size=200, class weight=None, coef0
=0.0,
  decision function shape='ovr', degree=3, gamma='auto deprecated',
  kernel='rbf', max iter=-1, probability=False, random state=None,
  shrinking=True, tol=0.001, verbose=False),
       fit params=None, iid='warn', n jobs=2,
       param grid={'gamma': array([1.00000e-06, 3.59381e-06, 1.29155
e-05, 4.64159e-05, 1.66810e-04,
       5.99484e-04, 2.15443e-03, 7.74264e-03, 2.78256e-02, 1.00000e-
01])},
       pre dispatch='2*n jobs', refit=True, return_train_score='war
n',
       scoring='accuracy', verbose=0)
```

실제 하드웨어의 코어 수가 부족하다면 병렬로 실행되지 않으므로 실행시간이 단축되지 않는다.